Búsqueda digital, tries, etc.

Motivación

- Tiempo menos dependiente de la cantidad de claves
- Rendimiento razonable en el peor caso
- Rápidos en la práctica
- Adecuados para claves de tamaño variable
- Adecuados para otro tipo de aplicaciones (por ej. pattern matching, indexación, en general “text retrieval”, compresión de textos

Idea:

- No hacer comparaciones de claves completas, sino de partes de ellas
- Requiere: poder hacer operaciones sobre esas partes.
- Por ejemplo:
  - si las claves son strings, vamos a trabajar con caracteres
  - si las claves son enteros, vamos a trabajar con dígitos, o bits.

Desventajas

- Algunas implementaciones pueden requerir mucha memoria
- Las operaciones sobre las componentes de las claves puede no ser fácil, o ser muy ineficiente en algunos lenguajes de alto nivel.

Árboles de búsqueda digital

- "Parecidos" a los ABB:
  - Para guardar una clave, vamos recorriendo el camino en el árbol que nos lleva a su posición
  - Pero la posición no está determinada por comparaciones por > o <, sino por los bits (o dígitos, o caracteres) de la clave

Árboles de búsqueda digital

- Ejemplo:

E	00101
J	01010
M	01101
P	10000
L	01100
O	01111
D	00100
B	00010
U	10101
S	10011
Q	10001
A	00001

Propiedades

- El peor caso es mucho mejor que el de los ABBs si
  - El número de claves es grande y
  - Las claves no son largas
- Longitud del camino más largo = mayor número de bits sucesivos iguales de dos claves cualesquiera a partir del bit más a la izquierda (o sea, mayor prefijo común)
- Búsqueda o inserción en un árbol de *n* claves de *b* bits, necesita en promedio (suponiendo bla, bla, bla...) *log n* comparaciones de clave completa, y *b* en el peor caso.

Tries

- Debidos a Friedkin, años `60
- Nombre proviene de “retrieval”
- Árbol (k+1)-ario para alfabetos de k elementos.
- Los ejes del árbol toman interés: representan componentes de las claves
- Por ejemplo:
  - si las claves son strings, los ejes representan caracteres
  - si las claves son enteros, los ejes representan dígitos, o bits.
- Cada subárbol representa al conjunto de claves que comienza con las etiquetas de los ejes que llevan hasta él
- Los nodos internos no contienen claves.
- Las claves o los punteros a la info, se almacenan en las hojas (a veces ni eso es necesario).

Ejemplo

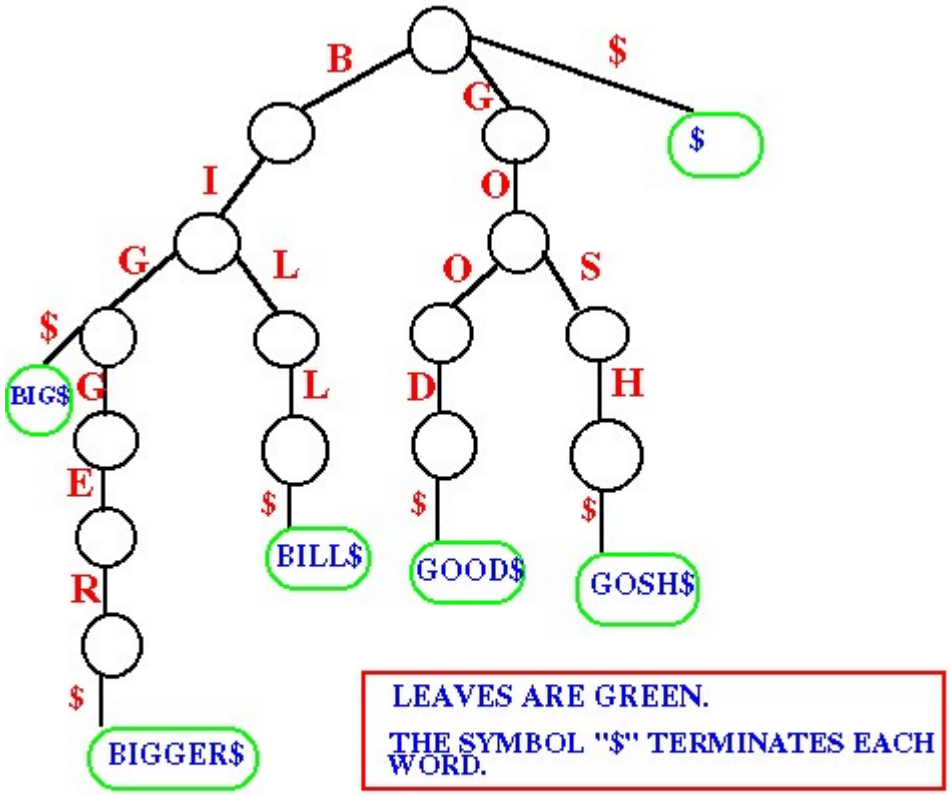

BIG
BIGGER
BILL
GOOD
GOSH

In this figure, the strings either start with B or G. Therefore, the root of the trie is connected to 3 edges called B, G and $.

Otro ejemplo

E	00101
J	01010
M	01101
P	10000
L	01100
O	01111
D	00100
B	00010
U	10101
S	10011
Q	10001
A	00001

Propiedades

- A lo sumo una comparación de clave completa (cuando llego a una hoja)
- La estructura del trie es la misma independientemente del orden en el que se insertan las claves (o sea...hay un único trie para un conjunto de claves)
- Búsqueda/inserción en un trie construido a partir de *n* claves de *b* bits, necesita ~*log n* comparaciones de bits en promedio (suponiendo bla bla bla….) y *b* comparaciones en el peor caso.

Implementación de tries

- Primera posibilidad: en cada nodo interno, un arreglo de punteros

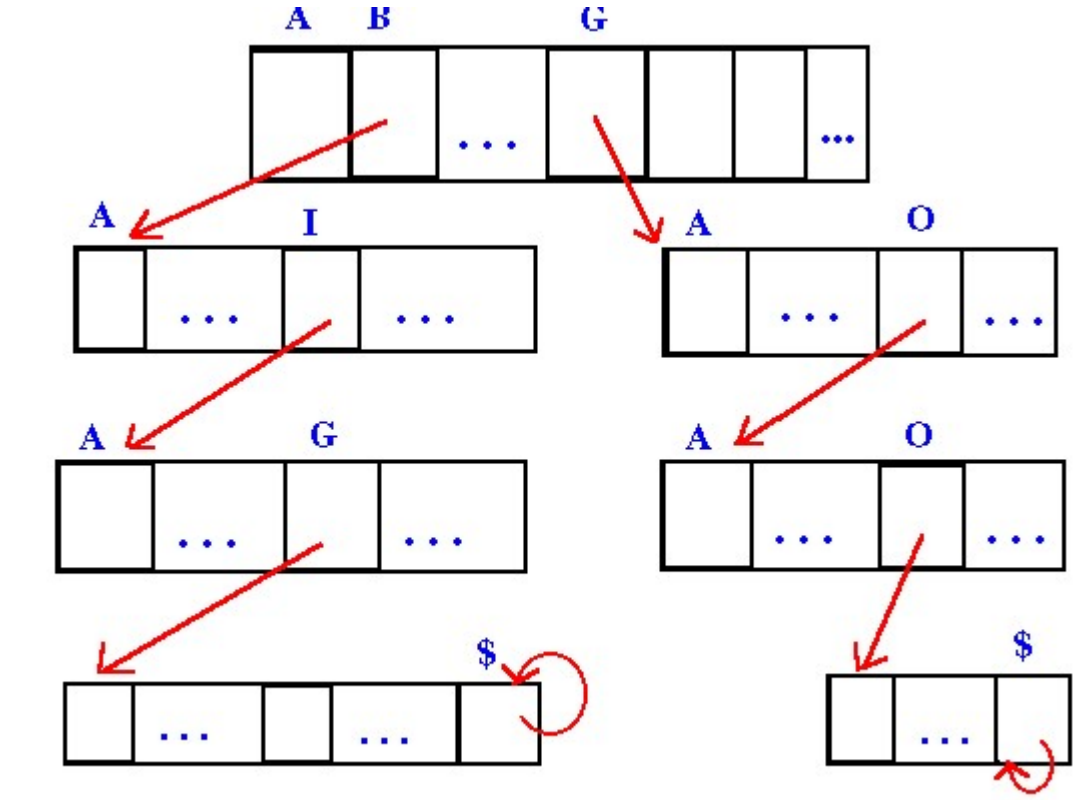

Trie representation for words BIG and GOO using array of pointers

- Muy eficiente en términos de tiempo
- Algoritmo simple
- ¡Puede ser extremadamente ineficiente en términos de memoria!
- Especialmente cuando:
  - Alfabeto grande
  - Diccionario chico
- Mitigaciones posibles:
  - Por ejemplo, agrupar caracteres poco frecuentes
  - (ver ejemplo con bits)

Implementación de tries

- Segunda posibilidad: hijos de un nodo representados a través de una lista encadenada.

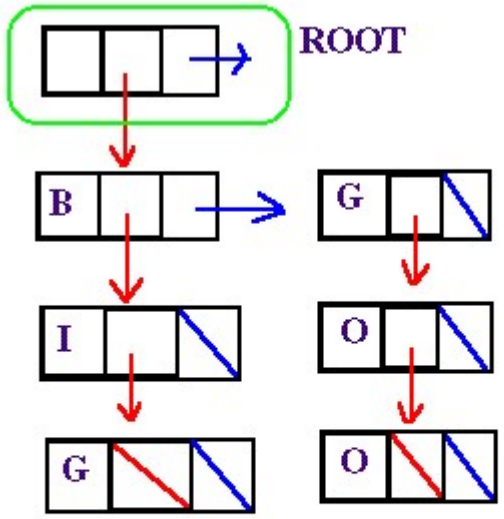

Trie representation for words BIG and GOO using linked lists

pointer to child pointer to sibling

- Eficiente en términos de tiempo sólo si hay pocas claves
- Requiere algoritmos sobre listas
- Mucho más eficiente en términos de memoria

Tries Compactos

- Parecidos, pero…..colapsamos las cadenas que llevan hacia hojas

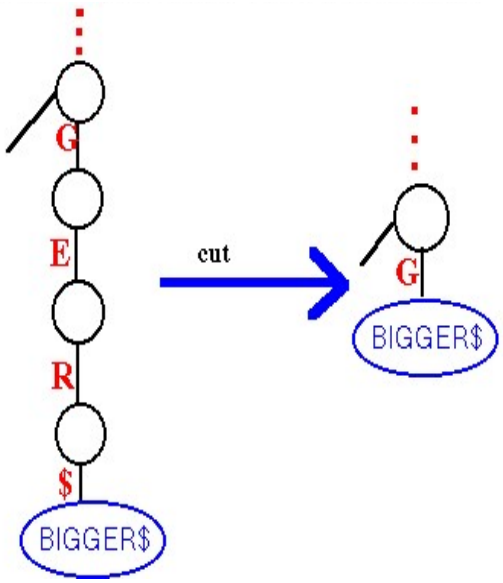

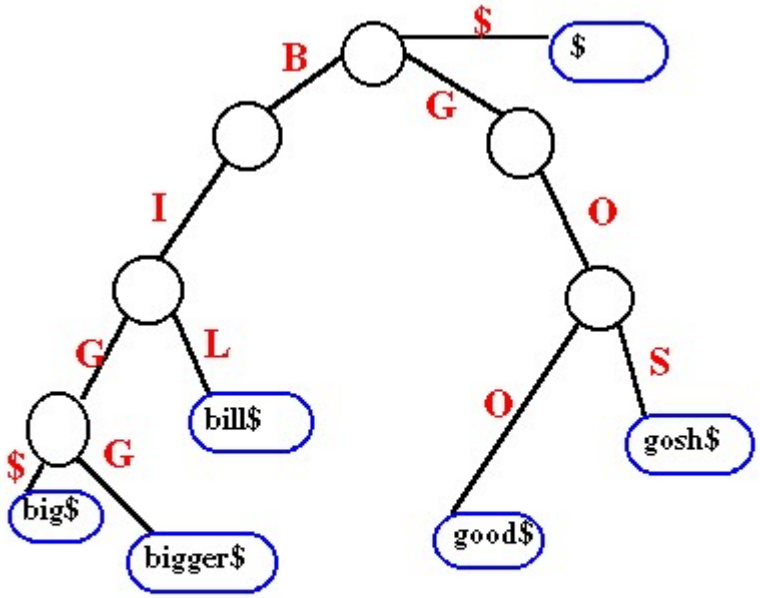

Trie for strings big, bigger, bill, good, gosh This trie is more compact than the trie in figure 2.

Tries más compactos: Patricia

- Patricia = Practical Algorithm To Retrieve Information Coded In Alphanumeric
- Debidos a D.R. Morrison
- Ahora colapsamos todas las cadenas
- Un eje puede representar más de un caracter.

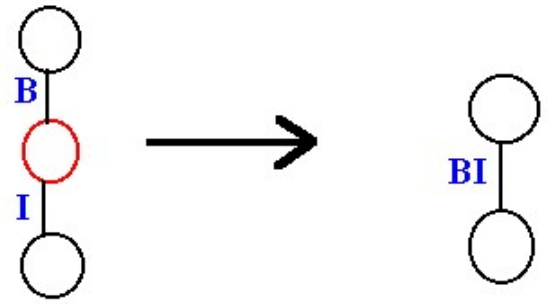

Before, one edge is used to represent a character.
Now, the red node (unary node) is collapsed and
one edge can hold more than one character.

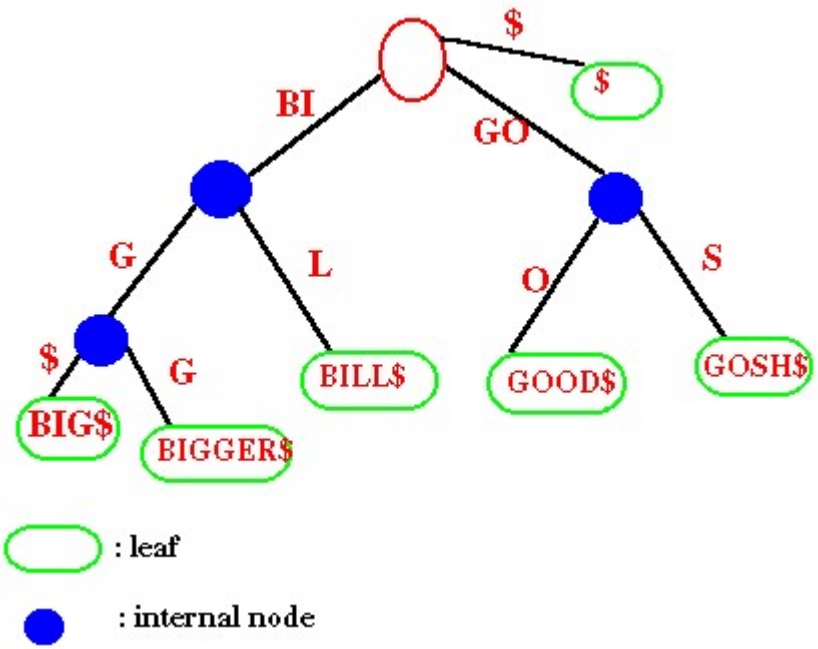

Para terminar

- La altura de un árbol Patricia binario está acotada por n (el número de claves).
- Eso no sucede con los modelos anteriores.
- En realidad, Patricia es un poco más elaborado, y hay numerosas variantes de los métodos vistos hoy.